Fondamentaux macroéconomiques et direction des devises : Le machine Learning apporte-t-il une solution ?

Une étude empirique sur cinq paires de devises majeurs à partir de données macroéconomiques (2003-2025)

Auteur :

Steevenson ALEXIS

Contents

Une étude empirique sur cinq paires de devises majeurs à partir de données macroéconomiques (2003-2025) 1
1.1. Le marché des changes : un enjeu majeur 5
1.2. Le puzzle académique : l'imprédictibilité des taux de change 5
1.3. Une nouvelle approche : le Machine Learning 5
1.4. Notre contribution : donnée macro récentes et XGBoost 6
1.5. Hypothèse unique 6
1.6. Organisation du document 7
2. Revue de Littérature 7
2.1. L'hypothèse d'efficience des marchés et la marche aléatoire 7
2.2. Le défi fondateur : Meese et Rogoff (1983) 8
2.2.1. La méthodologie et les résultats 8
2.2.2. Le "puzzle de Meese-Rogoff" 8
2.3. Les limites des modèles économétriques traditionnels 8
2.3.1. La rigidité de la forme fonctionnelle 8
2.3.2. L'instabilité des relations dans le temps 9
2.3.3. Les interactions complexes entre variables 9
2.4. L'émergence du Machine Learning en finance 9
2.4.1. Un changement de paradigme 9
2.4.2. L'étude fondatrice de Gu, Kelly et Xiu (2020) 9
2.4.3. Applications au marché des changes 10
2.5. Le dilemme prédiction vs. interprétabilité 10
2.5.1. Le prix de la performance 10
2.5.2. La limite fondamentale : corrélation vs. causalité 11
2.6. Synthèse et positionnement de notre étude 11
3. Données et Prétraitements 11
3.1. Source et acquisition des données 12
3.2. Structure des données 12
3.2.1. Les paires de devises étudiées 12
3.2.2. Les variables disponibles 12
3.3. Construction de la variable cible : direc_binaire 13
3.3.1. Choix de var_close 13
3.3.2. Création de *direc_binaire* 13
3.4. Périodes d'observation 14
3.4.1. Disponibilité différenciée des données 14

3.4.2. Décision méthodologique 14
3.5. Prétraitements appliqués 14
3.5.1. Gestion des valeurs manquantes 14
3.5.2. Création de variables retardées (lags) 14
3.5.3. Normalisation des features 15
3.5.4. Séparation entraînement/test 15
3.6. Équilibre de la variable cible 15
3.6. Équilibre de la variable cible 15
3.7. Limites des données 16
3.8. Préparation finale pour la modélisation 16
4. Méthodologie 16
4.1. Pourquoi XGBoost ? 16
4.1.1. Un algorithme de Machine Learning non paramétrique 16
4.1.2. Pourquoi XGBoost plutôt qu'un autre algorithme ? 17
4.2. Fonctionnement algorithmique de XGBoost 17
4.2.1. Principe du boosting 17
4.3. Validation temporelle 18
4.3.1. Éviter le look-ahead bias 18
4.4. Métriques d'évaluation 18
4.4.1. Matrice de confusion 18
4.4.2. Métriques retenues 19
4.4.3. Benchmark : le hasard 19
4.4.5. La limite fondamentale : corrélation vs. causalité 19
4.5. Synthèse méthodologique 19
4.6. Implémentation technique 20
5.1. Performance globale des modèles 20
5.2. Test de significativité par rapport au hasard 20
5.3. Analyse des hyperparamètres optimaux 21
5.4. Visualisation des résultats pour EUR/JPY 21
5.5. Synthèse des résultats 22
5.6. Limites observées dans les résultats 22
6 : Discussion 22
6.1. Retour sur l'hypothèse H0 22
6.2. Comparaison avec Meese et Rogoff (1983) 23
6.3. Comparaison avec Gu, Kelly et Xiu (2020) 23
6.4. Pourquoi EUR/JPY est-elle la seule paire significative ? 24

6.4.1. Le carry trade et l'asymétrie des taux 24
6.4.2. Le rôle des matières premières 24
6.4.4. La complexité du modèle 24
6.5. L'interprétabilité : un dilemme non résolu 25
6.6. Limites de l'étude 25
6.6.2. Limites des données 25
6.7. Implications pour la recherche et la pratique 25
6.7.1. Pour la recherche académique 25
6.7.2. Pour la pratique (trading) 26
6.8. Synthèse de la discussion 26
7 : Conclusion et Voies Futures 26
7.1. Rappel de la question de recherche et de la contribution 26
7.2. Synthèse des résultats 27
7.3. Réponse à la question de recherche 27
7.4. Implications pour la recherche et la pratique 28
7.4.1. Implications académiques 28
7.4.2. Implications pratiques (trading) 28
7.5. Limites de l'étude 28
7.6. Voies futures 28
7.6.1. Améliorations méthodologiques 28
7.6.2. Extension des données 29
7.6.3. Autres algorithmes 29
7.6.4. Horizons temporels 29
7.7. Conclusion finale 29
7.8. Disponibilité du code et des données 29

1. Introduction

1.1. Le marché des changes : un enjeu majeur

Le marché des changes est le plus grand marché financier mondial. Avec un volume quotidien de transactions dépassant 7 500 milliards de dollars en 2022,[1] il constitue le pivot des échanges internationaux, des investissements transfrontaliers et de la gestion des risques financiers. Les paires de devises majeures — EUR/USD, EUR/JPY, USD/CHF, USD/CAD, AUD/USD — concentrent l'essentiel de ces échanges.

La capacité à anticiper, ne serait-ce que partiellement, la direction future de ces taux de change représente un enjeu considérable. Pour les entreprises multinationales, une meilleure prévision permet d'optimiser la gestion du risque de change. Pour les investisseurs institutionnels, elle ouvre la voie à des stratégies de trading systématique. Pour les banques centrales, elle éclaire les décisions de politique monétaire.

1.2. Le puzzle académique : l'imprédictibilité des taux de change

Malgré cet enjeu pratique évident, la recherche académique a longtemps été dominée par une conclusion pessimiste. En 1983, Meese et Rogoff publient une étude fondatrice qui établit un résultat désormais célèbre : aucun modèle structurel basé sur les fondamentaux macroéconomiques (taux d'intérêt, inflation, croissance, etc.) ne parvient à prévoir les taux de change mieux qu'une simple marche aléatoire (random walk)[2].

En d'autres termes, la meilleure prédiction pour le taux de change de demain est le taux d'aujourd'hui. Ce résultat, connu sous le nom de "puzzle de Meese-Rogoff", a été confirmé par de nombreuses études ultérieures et constitue l'un des défis les plus tenaces de l'économie financière[3].

1.3. Une nouvelle approche : le Machine Learning

L'échec relatif des modèles économétriques traditionnels (régressions linéaires, modèles structurels) face à ce puzzle a conduit la recherche à explorer de nouvelles voies. Les relations entre les variables macroéconomiques et les taux de change sont probablement non-linéaires, instables dans le temps (time-varying) et dépendantes de régimes économiques changeants[4]. Or, les modèles économétriques classiques imposent une forme fonctionnelle rigide définie a priori.

C'est dans ce contexte que les algorithmes de Machine Learning ont émergé comme une alternative prometteuse. Des études récentes en finance, notamment celle de Gu, Kelly et Xiu (2020)[5], ont démontré que des méthodes comme le gradient boosting ou les réseaux de neurones surpassent

---

[1] *Bank for International Settlements (2022). Triennial Central Bank Survey of Foreign Exchange and Over-the-counter (OTC) Derivatives Markets.)*

[2] *Meese, R. A., & Rogoff, K. (1983). Empirical exchange rate models of the seventies: Do they fit out of sample? Journal of International Economics, 14(1-2), 3-24.)*

[3] *Obstfeld, M., & Rogoff, K. (2000). The six major puzzles in international macroeconomics: is there a common cause? NBER Macroeconomics Annual, 15, 339-390.)*

[4] Rossi, B. (2013). Exchange rate predictability. Journal of Economic Literature, 51(4), 1063-1119.)

[5] *Gu, S., Kelly, B., & Xiu, D. (2020). Empirical asset pricing via machine learning. The Review of Financial Studies, 33(5), 2223-2273.)*

significativement les régressions classiques pour la prédiction des rentabilités d'actifs, précisément parce qu'elles capturent des interactions complexes sans imposer de forme fonctionnelle prédéfinie.

Appliquée au marché des changes, cette approche reste encore émergente. Les études existantes montrent des résultats prometteurs mais mitigés, et aucune n'a encore bénéficié de données macroéconomiques récentes couvrant la période post-pandémique marquée par une forte volatilité et des changements de régime de politique monétaire.

1.4. Notre contribution : donnée macro récentes et XGBoost

C'est dans ce cadre que s'inscrit notre travail. Grâce à l'acquisition d'une base de données macroéconomique exhaustive auprès de Trading Economics, nous disposons d'un ensemble riche et actualisé d'indicateurs pour cinq paires de devises majeures, couvrant une période allant jusqu'en juin 2025. Ces données nous permettent de revisiter le puzzle de Meese-Rogoff avec des outils modernes et des informations récentes.

Notre question de recherche est la suivante :

"Un algorithme de Machine Learning (XGBoost) peut-il prédire la direction mensuelle des paires de devises majeures à partir de données macroéconomiques, avec une performance supérieure au hasard ?"

- Nous nous concentrons sur la direction du mouvement (hausse ou baisse) plutôt que sur son amplitude pour deux raisons :
- D'un point de vue pratique, les stratégies de trading directionnelles (long/short) sont les plus courantes.
- D'un point de vue méthodologique, prédire le signe est souvent considéré comme un test plus robuste de la capacité prédictive, car moins sensible aux valeurs extrêmes[6].

1.5. Hypothèse unique

Notre travail repose sur une hypothèse unique, que nous testerons sur l'ensemble des cinq paires :

H0 : Un modèle de Machine Learning non-linéaire (XGBoost) entraîné sur des données macroéconomiques mensuelles permet de prédire la direction des paires de devises majeures avec une précision statistiquement supérieure à celle du hasard (50%).

Cette performance prédictive, si elle est avérée, se fera toutefois au prix d'une interopérabilité économique limitée. XGBoost étant un algorithme de type "boîte noire" (black box), il pourra indiquer quoi prédire mais non pourquoi au sens causal du terme. Pour explorer cette question, nous utiliserons l'outil SHAP[7], afin d'identifier les variables les plus importantes dans les décisions du modèle.

---

[6] *Christoffersen, P. F., & Diebold, F. X. (2006). Financial asset returns, direction-of-change forecasting, and volatility dynamics. Management Science, 52(8), 1273-1287.)*

[7] *Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. Advances in Neural Information Processing Systems, 30.)*

1.6. Organisation du document

La suite de ce travail est structurée comme suit. La section 2 présente une revue de la littérature sur la prédiction des taux de change, en insistant sur le passage des modèles économétriques aux approches de Machine Learning. La section 3 décrit les données utilisées (source, variables, périodes, prétraitements) et la construction de la variable cible direc_binaire. La section 4 expose la méthodologie : présentation de XGBoost (algorithme de Machine Learning non paramétrique), choix des hyper paramètres, validation temporelle et métriques d'évaluation. La section 5 livre les résultats empiriques paire par paire. La section 6 discute ces résultats à la lumière de la littérature existante. Enfin, la section 7 conclut et propose des pistes pour des recherches futures

2. Revue de Littérature

Cette section présente les fondements théoriques et empiriques qui justifient notre approche. Nous retraçons le cheminement de la recherche sur la prédiction des taux de change, depuis le constat fondateur d'imprédictibilité jusqu'aux récentes avancées du Machine Learning.

2.1. L'hypothèse d'efficience des marchés et la marche aléatoire

Le point de départ théorique de toute discussion sur la prédictibilité des prix financiers est l'hypothèse des marchés efficients (Efficient Market Hypothesis - EMH), formulée par Eugène Fama à la fin des années 1960 et synthétisée en 1970[8].

Selon cette hypothèse, dans un marché efficient, les prix des actifs reflètent toute l'information disponible à un instant donné. Une conséquence directe en découle : il est impossible de prédire systématiquement les variations de prix, car celles-ci ne peuvent résulter que de l'arrivée de nouvelles informations, lesquelles sont par définition imprévisibles.

La forme semi-forte de l'EMH est particulièrement pertinente pour notre étude. Elle postule que les prix intègrent toute l'information publique, y compris les annonces macroéconomiques (taux d'intérêt, inflation, croissance, etc.). Si cette forme est vérifiée, alors notre tentative de prédire les taux de change à l'aide de données macroéconomiques publiques est vouée à l'échec.

Une conséquence empirique de l'EMH est que les variations de prix devraient suivre une marche aléatoire (random walk) :

$$P_{t+1}=P_t+\varepsilon_{t+1}$$

Où ε_{t+1} est un bruit blanc imprédictible. En d'autres termes, la meilleure prédiction du prix de demain est le prix d'aujourd'hui.

[8] Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. The Journal of Finance, 25(2), 383-417.)*

2.2. Le défi fondateur : Meese et Rogoff (1983)

2.2.1. La méthodologie et les résultats

L'étude la plus célèbre et la plus influente sur l'imprédictibilité des taux de change est sans conteste celle de Meese et Rogoff (1983)[9]. Les auteurs comparent la performance prédictive hors échantillon (out-of-sample) de plusieurs modèles structurels de détermination des taux de change avec celle d'une simple marche aléatoire.

Les modèles testés incluent :

- Le modèle monétaire (flexible prices)
- Le modèle monétaire avec prix rigides (Dornbusch overshooting)
- Le modèle d'équilibre de portefeuille (portfolio balance)

Les données couvrent la période des années 1970 et les principales devises (dollar américain contre mark allemand, yen japonais, livre sterling).

Le résultat est sans appel : aucun des modèles structurels ne parvient à battre la marche aléatoire pour les prévisions à des horizons de 1 à 12 mois. La conclusion de Meese et Rogoff est devenue un résultat stylisé en économie internationale :

"Les modèles structurels ne peuvent pas prévoir les taux de change mieux qu'une marche aléatoire, même en utilisant les valeurs réalisées des variables explicatives dans les prévisions"[10].

2.2.2. Le "puzzle de Meese-Rogoff"

Ce résultat, confirmé par de nombreuses études ultérieures, est devenu ce que la littérature nomme le "puzzle de Meese-Rogoff" ou le "puzzle de la prédiction des taux de change[11] (exchange rate disconnect puzzle)[12]. Il suggère que les taux de change sont largement déconnectés des fondamentaux macroéconomiques à court et moyen terme, remettant en cause des décennies de modélisation théorique.

Ce puzzle a profondément influencé la recherche en finance internationale. Il a conduit de nombreux chercheurs à abandonner la quête de modèles structurels performants à court terme, ou à chercher des explications alternatives (flux d'ordres, microstructures, comportement des investisseurs) pour expliquer les mouvements de change.

2.3. Les limites des modèles économétriques traditionnels

2.3.1. La rigidité de la forme fonctionnelle

Les modèles économétriques traditionnels (régression linéaire, logit, modèles structurels) partagent une caractéristique commune : ils imposent une forme fonctionnelle prédéfinie avant toute

---

[9] *Meese, R. A., & Rogoff, K. (1983). Empirical exchange rate models of the seventies: Do they fit out of sample? Journal of International Economics, 14(1-2), 3-24.)*

[11] Obstfeld, M., & Rogoff, K. (2000). The six major puzzles in international macroeconomics: is there a common cause? NBER Macroeconomics Annual, 15, 339-390.)*

Estimation. Par exemple, une régression logistique postule que la relation entre les variables explicatives et la probabilité de hausse est linéaire dans les log-odds.

Cette linéarité est une hypothèse forte, rarement vérifiée dans les données financières. Or, si la forme fonctionnelle est mal spécifiée, les estimations deviennent biaisées et les prédictions inefficaces.

2.3.2. L'instabilité des relations dans le temps

De nombreuses études ont montré que les relations entre les fondamentaux macroéconomiques et les taux de change ne sont pas stables dans le temps (time-varying)[13]. Une variable qui est un bon prédicteur sur une période peut perdre toute pertinence sur une autre, en raison de changements de régime de politique monétaire, de chocs exogènes ou d'évolutions structurelles des économies.

Cette instabilité rend difficile l'estimation de modèles paramétriques qui supposent des coefficients constants sur toute la période d'étude.

2.3.3. Les interactions complexes entre variables

Les modèles économétriques standards peinent également à capturer les interactions complexes entre variables. Par exemple, l'effet d'un différentiel de taux d'intérêt sur la direction de l'EUR/USD peut dépendre du niveau du VIX (indice de peur), du prix du pétrole, ou du différentiel de croissance. Capturer ces interactions nécessiterait d'introduire des termes d'interaction (produits de variables), ce qui devient rapidement inopérant lorsque le nombre de variables augmente (explosion combinatoire).

2.4. L'émergence du Machine Learning en finance

2.4.1. Un changement de paradigme

Face aux limites des modèles économétriques traditionnels, un changement de paradigme s'est opéré dans la recherche financière à partir des années 2010. Plutôt que d'imposer une forme fonctionnelle rigide, les approches de Machine Learning (apprentissage automatique) permettent d'apprendre la relation entre les variables directement à partir des données, sans la spécifier a priori[14].

Ce changement est fondamental. Là où l'économètre spécifie une équation avant de l'estimer, le praticien du Machine Learning fournit les données et laisse l'algorithme découvrir la structure sous-jacente. Cette flexibilité est particulièrement précieuse lorsque les relations sont non-linéaires, instables, ou font intervenir des interactions complexes.

2.4.2. L'étude fondatrice de Gu, Kelly et Xiu (2020)

L'article le plus influent dans ce domaine est sans doute celui de Gu, Kelly et Xiu (2020), intitulé "*Empirical Asset Pricing via Machine Learning*"[15]. Les auteurs comparent une vaste gamme d'algorithmes de Machine Learning (régression linéaire pénalisée, forêts aléatoires, gradient boosting, réseaux de neurones) pour prédire les rentabilités d'actions individuelles à partir de centaines de caractéristiques firmes.

---

[13] *Rossi, B. (2013). Exchange rate predictability. Journal of Economic Literature, 51(4), 1063-1119.)**

[14] *Varian, H. R. (2014). Big data: New tricks for econometrics. Journal of Economic Perspectives, 28(2), 3-28.)*

[15] *Gu, S., Kelly, B., & Xiu, D. (2020). Empirical asset pricing via machine learning. The Review of Financial Studies, 33(5), 2223-2273.)*

Leurs conclusions sont claires :

- Les modèles de Machine Learning surpassent systématiquement les régressions linéaires traditionnelles.
- Les algorithmes les plus performants sont ceux qui intègrent une forte régularisation et capturent les non-linéarités, notamment le gradient boosting et les réseaux de neurones.
- Cette performance prédictive est économiquement significative et se traduit par des gains réels en termes de stratégies d'investissement.
- Cette étude a ouvert la voie à une multiplication des applications du Machine Learning en finance, y compris sur le marché des changes.

2.4.3. Applications au marché des changes

Plusieurs études ont tenté d'appliquer le Machine Learning à la prédiction des taux de change, souvent avec l'ambition de revisiter le puzzle de Meese-Rogoff :

- Plakandaras et al. (2015)[16] montrent que des modèles de régression avec régularisation (LASSO, Ridge) et des machines à vecteurs de support (SVM) améliorent la prédiction des taux de change par rapport aux modèles linéaires classiques, mais avec des gains modestes.
- Colacito et al. (2020) [17] utilisent des méthodes de Machine Learning pour combiner des centaines de prédicteurs macroéconomiques et montrent qu'il est possible de battre la marche aléatoire à des horizons de 1 à 3 mois, contrairement aux résultats originaux de Meese et Rogoff.
- Yıldırım et al. (2021) [18] comparent spécifiquement le gradient boosting (XGBoost) aux réseaux de neurones pour la prédiction des devises des pays émergents et concluent à la supériorité du boosting pour ce type de données.

Ces résultats sont prometteurs mais mitigés. Ils suggèrent que le Machine Learning peut apporter un léger avantage prédictif, mais que la prédiction des taux de change reste un problème fondamentalement difficile.

2.5. Le dilemme prédiction vs. interprétabilité

2.5.1. Le prix de la performance

L'un des principaux reproches adressés au Machine Learning, en particulier dans un contexte académique, est son caractère de "boîte noire" (black box). Un algorithme comme XGBoost peut faire d'excellentes prédictions, mais il est difficile, voire impossible, d'expliquer pourquoi une prédiction a été faite.

---

[16] *Plakandaras, V., Papana, A., & Kyrtsou, C. (2015). Forecasting exchange rates with machine learning: insights from the recent crisis. Computational Economics, 45(3), 447-468.)*

[17] *Colacito, R., Riddiough, S. J., & Sarno, L. (2020). Business cycles and currency returns. Journal of Financial Economics, 137(3), 659-683.)*

[18] *Yıldırım, D. Ç., Torun, F., & Esen, Ö. (2021). Forecasting exchange rates with machine learning: The case of emerging markets. Central Bank Review, 21(4), 141-151.)*

Ce dilemme est bien connu en économétrie : les modèles paramétriques (comme la régression logistique) sont interprétables mais souvent moins performants en prédiction ; les modèles non-paramétriques (comme XGBoost) sont plus performants mais moins interprétables.

Cette approche permet d'identifier les variables les plus importantes globalement et de comprendre, observation par observation, les facteurs qui ont orienté la prédiction.

2.5.2. La limite fondamentale : corrélation vs. causalité

Cependant — et c'est un point crucial pour notre hypothèse — SHAP révèle des corrélations apprises par le modèle, non des relations causales. Lorsque SHAP indique que le différentiel de taux d'intérêt a contribué à une prédiction de hausse de l'EUR/USD, cela signifie que le modèle a appris une association statistique entre ces deux variables dans les données d'entraînement. Cela ne permet pas d'affirmer que le différentiel de taux cause ce mouvement au sens économique du terme.

Cette distinction est fondamentale : une performance prédictive significative peut coexister avec une absence d'explication économique causale claire. C'est précisément le sens de notre hypothèse H0.

2.6. Synthèse et positionnement de notre étude

La revue de littérature que nous venons de parcourir nous permet de positionner clairement notre contribution :

Élément	**Conclusion de la littérature**	**Positionnement de notre étude**
Meese & Rogoff (1983)	Les modèles structurels ne battent pas la marche aléatoire	Nous revisitons ce résultat avec des données actualisées (jusqu'en 2025) et un algorithme de ML
Limites des modèles économétriques	Forme fonctionnelle rigide, instabilité, interactions complexes	Le ML (XGBoost) répond à ces limites en apprenant la relation sans la spécifier a priori
Gu, Kelly & Xiu (2020)	Le ML surpasse la régression linéaire en actions	Nous transposons cette approche au marché des changes
Applications ML au Forex	Résultats prometteurs mais mitigés	Nous testons XGBoost sur 5 paires majeures avec des données macro récentes (jusqu'en 2025)
Dilemme prédiction vs. Interprétabilité	Le ML est performant mais peu interprétable	Nous utilisons SHAP pour explorer l'interprétabilité, tout en reconnaissant ses limites

Cette revue de littérature justifie donc notre unique hypothèse :

H0 : Un modèle de Machine Learning non-linéaire (XGBoost) entraîné sur des données macroéconomiques mensuelles permet de prédire la direction des paires de devises majeures avec une précision statistiquement supérieure à celle du hasard (50%), mais cette performance prédictive ne se traduit pas nécessairement par une explication économique causale claire.

3. Données et Prétraitements

Cette section présente la source, la structure et les transformations appliquées aux données avant l'estimation du modèle XGBoost. La transparence de cette étape est essentielle pour la reproductibilité de l'étude, conformément aux standards académiques[19].

3.1. Source et acquisition des données

Les données utilisées dans cette étude proviennent d'un achat auprès de Trading Economics[20], fournisseur reconnu de données macroéconomiques et financières. Cet achat nous garantit :

L'exhaustivité : Un large spectre d'indicateurs macroéconomiques pour plusieurs pays.

La fiabilité : Des données nettoyées et harmonisées, issues de sources officielles (banques centrales, instituts nationaux de statistique).

L'actualisation : Des données couvrant une période allant jusqu'en juin 2025, ce qui permet d'intégrer les années post-pandémiques récentes, marquées par une forte volatilité et des changements de régime de politique monétaire.

L'usage de données acquises commercialement, bien que représentant un coût, est courant dans la recherche empirique en finance et garantit une qualité supérieure aux données collectées automatiquement sur le web sans vérification[21]

3.2. Structure des données

3.2.1. Les paires de devises étudiées

Cinq paires de devises majeures sont analysées. Le tableau ci-dessous présente leurs caractéristiques essentielles :

Paire	Description	Caractéristique particulière
EUR/USD	Euro / Dollar américain	Paire la plus liquide au monde
EUR/JPY	Euro / Yen japonais	Sensible au carry trade (taux bas au Japon)
USD/CHF	Dollar / Franc suisse	Valeur refuge (safe haven)
USD/CAD	Dollar / Dollar canadien	Devise "commodity" liée au pétrole
AUD/USD	Dollar australien / Dollar	Devise "commodity" liée aux matières premières minières

3.2.2. Les variables disponibles

Pour chaque paire, le fichier contient les colonnes suivantes (nous conservons la nomenclature originale) :

Catégorie	Variables	Description

[19] *Les données et les codes Python utilisés pour cette étude sont intégralement disponibles sur le dépôt GitHub accompagnant cet article*

[20] *Trading Economics. (2025). Base de données macroéconomiques [Fichier de données]. Achetée en [mois/année].)*

[21] *Nous reconnaissons que l'accès à ces données est payant, ce qui peut constituer une limite à la reproductibilité universelle. Cependant, le fournisseur propose des abonnements académiques.)*

Identification	Date	Date de l'observation (format mensuel)
Croissance	croiss_b, croiss_c, diff_croiss	Croissance du PIB du pays base/coté et leur différence
Taux d'intérêt	taux_int_b, taux_int_c, diff_taux_int	Taux directeurs et leur différence
Inflation	infl_b, infl_c, diff_infl	IPC (Indice des Prix à la Consommation) et différence
Chômage	chomage_b, chomage_c, diff_chomage	Taux de chômage et différence
Balance commerciale	b_com_b, b_com_c	Balance commerciale des deux pays
Masse monétaire	mas_mon_b, mas_mon_c, diff_mas_mon	Agrégats monétaires (M2 généralement)
Variables globales	vix, prix_du_pe	Indice de volatilité VIX, prix du pétrole
Cible (target)	Close, var_pips, var_close, acc_var_close	Prix de clôture, variation en pips, variation en %, variation accumulé

3.3. Construction de la variable cible : direc_binaire

3.3.1. Choix de var_close

La variable var_close représente la variation en pourcentage du taux de change entre deux mois consécutifs :

var_closet_t = ((Close$_t$−1Closet_t)/Close$_t$−1)100

Cette mesure relative est préférable à var_pips (variation absolue) car elle standardise les mouvements entre paires de devises ayant des niveaux de prix très différents (un pip sur l'USD/CAD n'a pas le même poids relatif que sur l'EUR/JPY). La littérature académique privilégie généralement les rendements logarithmiques ou les variations en pourcentage pour cette raison[22].

3.3.2. Création de *direc_binaire*

À partir de var_close, nous construisons une variable binaire indicatrice du sens du mouvement mensuel

direc_binaire$_t$ = 1 si *var_close*$_t$ > 0 et 0 si *var_close*$_t$≤ 0

Cette transformation est appliquée pour chaque paire de devises. Le choix de la cible binaire plutôt que de la variation continue est justifié par :

Robustesse : La prédiction du signe est moins sensible aux valeurs extrêmes qui parasitent souvent les séries financières.

Opérationnalité : Une stratégie de trading directionnelle (long/short) ne nécessite qu'une prédiction du signe.

---

[22] *Campbell, J. Y., Lo, A. W., & MacKinlay, A. C. (1997). The Econometrics of Financial Markets. Princeton University Press.)*

Comparabilité : Les métriques de classification (accuracy, F1-score) sont plus intuitives pour évaluer un modèle prédictif[23].

3.4. Périodes d'observation

3.4.1. Disponibilité différenciée des données

Un défi important de notre base de données est que les observations ne débutent pas à la même date pour toutes les paires. Cela est dû à la disponibilité historique des données macroéconomiques harmonisées par Trading Economics.

Paire	Date de début	Date de fin	Nombre d'observations
EUR/USD	30/04/2004	30/06/2025	255
EUR/JPY	31/05/2003	30/06/2025	266
USD/CHF	31/12/2003	30/06/2025	259
USD/CAD	31/12/2003	30/06/2025	227
AUD/USD	31/08/2006	30/06/2025	259

3.4.2. Décision méthodologique

Face à ce décalage, nous adoptons la stratégie suivante :

1. Analyse individuelle par paire : Le modèle XGBoost sera estimé séparément pour chaque paire, en utilisant la totalité de la période disponible pour cette paire. Cela maximise le nombre d'observations et donc la puissance statistique des tests.
2. Pas de fusion globale : Nous ne cherchons pas à créer un unique jeu de données panel avec toutes les paires, car les dates non communes réduiraient considérablement l'échantillon (perte des données 2003-2006 pour l'AUD/USD notamment).
3. Date de fin commune : Toutes les paires partagent la même date de fin (juin 2025), ce qui garantit que les résultats sont comparables sur la période récente.

3.5. Prétraitements appliqués

3.5.1. Gestion des valeurs manquantes

L'inspection des données révèle la présence de quelques valeurs manquantes (notamment pour les premiers mois de certaines séries macroéconomiques publiées avec retard). En raison du faible nombre de valeurs manquantes (< 1% de l'échantillon pour chaque paire), nous procédons à une suppression des lignes concernées plutôt qu'à une imputation, pour ne pas introduire de biais artificiel.

3.5.2. Création de variables retardées (lags)

Pour respecter la chronologie et éviter le look-ahead bias (biais de regard vers le futur), nous créons des versions décalées des variables explicatives. Au moment de prédire la direction du mois t, nous n'utilisons que les données macroéconomiques disponibles à la fin du mois $_{t-1}$:

$X_t^{\text{features}} = \{X_{t-1}^{\text{macro}}, X_{t-2}^{\text{macro}}, \ldots\}$

[23] *Christoffersen, P. F., & Diebold, F. X. (2006). Financial asset returns, direction-of-change forecasting, and volatility dynamics. Management Science, 52(8), 1273-1287.)*

Dans notre implémentation, nous utilisons un décalage d'un mois (lag 1) pour toutes les variables macroéconomiques.

3.5.3. Normalisation des features

XGBoost est moins sensible à l'échelle des variables que d'autres algorithmes (comme les réseaux de neurones ou les SVM). Cependant, la normalisation peut faciliter la convergence et améliorer la stabilité du modèle. Nous appliquons une standardisation (Z-score) :

$X_{scaled} = (x - \mu_{train}) / \sigma_{train}$

Où μ et σ_t sont calculés sur la période d'entraînement uniquement, pour éviter tout biais de fuite d'information vers la période de test.

3.5.4. Séparation entraînement/test

Éviter le look-ahead bias est impératif en prévision financière. Nous adoptons une validation temporelle : les données antérieures servent à entraîner le modèle, les données plus récentes à le tester.

Pour chaque paire de devises :

- Période d'entraînement : 70% des premières observations.
- Période de test : 30% des dernières observations (les plus récentes, jusqu'en juin 2025).

Cette répartition respecte l'ordre temporel et correspond à un exercice réaliste de prévision hors échantillon.

3.6. Équilibre de la variable cible

Un élément crucial pour la modélisation est l'équilibre de la variable cible direc_binaire. Un déséquilibre trop marqué (par exemple 80% de hausses et 20% de baisses) pourrait affecter la performance du modèle et nécessiterait des ajustements méthodologiques (ré échantillonnage, pondération des classes).

L'analyse de la distribution par paire (à compléter après chargement des données) nous permettra de vérifier l'équilibre global.

3.6. Équilibre de la variable cible

Un élément crucial pour la modélisation est l'équilibre de la variable cible direc_binaire. Un déséquilibre trop marqué (par exemple 80% de hausses et 20% de baisses) pourrait affecter la performance du modèle et nécessiterait des ajustements méthodologiques (ré échantillonnage, pondération des classes).

L'analyse de la distribution par paire (à compléter après chargement des données) nous permettra de vérifier l'équilibre global.

Paire	Proportion de hausses (1)	Proportion de baisses (0)
EUR/USD	125	130
EUR/JPY	147	119
USD/CHF	120	139
USD/CAD	127	132
AUD/USD	115	112

3.7. Limites des données

Nous identifions trois limites principales concernant nos données :

Fréquence mensuelle : Les décisions des traders et les réactions aux annonces macroéconomiques se produisent à des échelles de temps beaucoup plus fines (minutes, heures, jours). Une fréquence mensuelle peut lisser une partie de l'information pertinente.

Données révisées : Les indicateurs macroéconomiques (PIB, inflation) sont souvent révisés après leur première publication. Notre base de données contient les valeurs définitives, alors qu'un trader en temps réel ne disposerait que des valeurs préliminaires. Cela peut introduire un léger biais de "surperformance" des modèles.

Absence de certaines variables : Des facteurs potentiellement importants comme les flux d'ordres (order flow), les positions des spéculateurs (données COT - Commitment of Traders), ou le sentiment tiré de l'analyse textuelle des discours des banques centrales ne sont pas inclus.

3.8. Préparation finale pour la modélisation

À l'issue de ces prétraitements, nous disposons, pour chaque paire, d'un jeu de données structuré de la manière suivante :

Features (X) : Ensemble des variables macroéconomiques décalées d'un mois (_lag1) et standardisées.

Target (y) : Variable direc_binaire (0/1) pour le mois suivant.

Ces données sont désormais prêtes à être utilisées pour estimer le modèle XGBoost et tester notre hypothèse H3 dans la section méthodologique qui suit.

4. Méthodologie

Cette section présente le cadre méthodologique de notre étude. Nous décrivons successivement :

- la justification du choix de XGBoost comme algorithme de Machine Learning,
- son fonctionnement algorithmique,
- la procédure de validation temporelle,
- les métriques d'évaluation
- l'utilisation de SHAP pour l'interprétation des prédictions.

4.1. Pourquoi XGBoost ?

4.1.1. Un algorithme de Machine Learning non paramétrique

XGBoost appartient à la famille des algorithmes de Machine Learning supervisé. Contrairement aux modèles économétriques traditionnels (régression logistique, modèles linéaires), XGBoost ne repose sur aucune équation prédéfinie reliant les variables explicatives à la variable cible.

Cette distinction est fondamentale :

Critère	Modèles économétriques (Logit, etc.)	XGBoost (Machine Learning)
Forme fonctionnelle	Prédéfinie avant estimation	Apprise à partir des données
Équation	$f(X) = \beta_0 + \beta_1 X_1 + ...$	Aucune équation unique

Objectif principal	Inférence (tester des hypothèses causales)	Prédiction (maximiser la performance)
Interprétabilité	Élevée (coefficients, p-values)	Faible (boîte noire)

L'absence de forme fonctionnelle prédéfinie confère à XGBoost une flexibilité précieuse pour capturer :

- Des relations non-linéaires entre les variables macroéconomiques et la direction des devises.
- Des interactions complexes (par exemple, l'effet du différentiel de taux peut dépendre du niveau du VIX).
- Des effets de seuil (une variable peut n'avoir d'impact qu'au-delà d'un certain niveau).

4.1.2. Pourquoi XGBoost plutôt qu'un autre algorithme ?

Parmi les nombreux algorithmes de Machine Learning, nous retenons XGBoost pour plusieurs raisons, confirmées par la littérature académique récente[2] :

Performance prédictive : XGBoost a dominé de nombreuses compétitions de Machine Learning et s'est imposé comme une référence pour les problèmes de classification sur données tabulaires.

Régularisation intégrée : L'algorithme intègre des termes de pénalisation (L1 et L2) qui limitent le sur-apprentissage, un risque majeur lorsqu'on utilise des modèles complexes sur des séries temporelles financières.

Gestion des valeurs manquantes : XGBoost apprend automatiquement la direction optimale pour traiter les valeurs manquantes, sans nécessiter d'imputation préalable.

Robustesse : L'algorithme est relativement robuste à l'échelle des variables.

Interprétabilité post-hoc : Bien que XGBoost soit une boîte noire, des outils comme SHAP permettent d'explorer ses décisions.

4.2. Fonctionnement algorithmique de XGBoost

4.2.1. Principe du boosting

XGBoost repose sur le principe du gradient boosting, introduit par Friedman (2001)[24]. L'idée est de combiner plusieurs modèles "faibles" (généralement des arbres de décision peu profonds) pour créer un modèle "fort".

Le processus est itératif :

- On initialise avec un modèle très simple (généralement une prédiction constante).
- À chaque itération, on calcule les résidus (erreurs) du modèle actuel.
- On entraîne un nouvel arbre de décision à prédire ces résidus.
- On ajoute ce nouvel arbre au modèle, avec un poids faible.

On répète l'opération des centaines ou milliers de fois.

---

[24] *Friedman, J. H. (2001). Greedy function approximation: a gradient boosting machine. The Annals of Statistics, 29(5), 1189-1232.)*

À la fin, le modèle final est une somme pondérée de centaines de petits arbres de décision. Aucune équation unique ne résume cette somme — la relation entre les variables d'entrée et la prédiction est trop complexe pour être représentée par une formule paramétrique simple.

4.3. Validation temporelle

4.3.1. Éviter le look-ahead bias

En prévision financière, il est impératif d'éviter tout biais de regard vers le futur. Une prédiction pour le mois$_t$ ne doit utiliser que les informations disponibles avant ce mois.

Nous adoptons une validation temporelle (time series split) plutôt qu'une validation croisée aléatoire. Pour chaque paire de devises :

Période d'entraînement : 70% des premières observations (les plus anciennes)

Période de test : 30% des dernières observations (les plus récentes, jusqu'en juin 2025)

Cette répartition respecte l'ordre temporel et correspond à un exercice réaliste de prévision hors échantillon.

XGBoost comporte plusieurs hyperparamètres qui contrôlent la complexité du modèle. Nous les optimisons par recherche sur grille (grid search) sur la période d'entraînement uniquement, en utilisant une validation croisée temporelle pour éviter le sur-apprentissage.

Les principaux hyperparamètres optimisés sont :

Hyperparamètre	Description	Plage explorée
n_estimators	Nombre d'arbres	100, 200
max_depth	Profondeur maximale des arbres	3, 5, 7, 10
learning_rate	Taux d'apprentissage	0.01, 0.05, 0.1, 0.3
Subsample	Fraction des données utilisée par arbre	0.6, 0.8, 1.0
colsample_bytree	Fraction des features utilisées par arbre	0.6, 0.8, 1.0
reg_alpha	Pénalité L1	0, 0.01, 0.1, 1
reg_lambda	Pénalité L2	0.1, 1, 10

4.4. Métriques d'évaluation

Pour évaluer la performance prédictive de XGBoost, nous utilisons plusieurs métriques de classification.

4.4.1. Matrice de confusion

Toutes les métriques sont dérivées de la matrice de confusion, qui croise les prédictions avec la réalité :

	Prédit : Hausse (1)	Prédit : Baisse (0)
Réel : Hausse (1)	VP (Vrais Positifs)	FN (Faux Négatifs)
Réel : Baisse (0)	FP (Faux Positifs)	VN (Vrais Négatifs

4.4.2. Métriques retenues

Métrique	Formule	Interprétation
Accuracy	$\frac{VP + VN}{VP + FP + VN + FN}$	Proportion de prédictions correctes (hausses et baisses confondues)
Précision	$\frac{VP}{VP + FP}$	Parmi les hausses prédites, proportion de vraies hausses
Rappel (Recall)	$\frac{VP}{VP + FN}$	Parmi les vraies hausses, proportion correctement prédites
F1-score	$2 \times \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}$	Moyenne harmonique de la précision et du rappel
AUC-ROC	Surface sous la courbe ROC	Capacité du modèle à distinguer hausses et baisses (1 = parfait, 0.5 = aléatoire)

4.4.3. Benchmark : le hasard

Conformément à la littérature issue de Meese et Rogoff (1983), nous prenons comme benchmark minimal une prédiction aléatoire avec une probabilité de 0.5 (pile ou face). Toute performance supérieure à ce benchmark doit être considérée comme une forme de prédictibilité.

Nous testons si l'accuracy de notre modèle est statistiquement supérieure à 0.5 à l'aide d'un test binomial au seuil de 5%.

4.4.5. La limite fondamentale : corrélation vs. causalité

C'est ici que se situe le cœur de notre hypothèse H3. SHAP révèle des corrélations apprises par le modèle, non des relations causales.

Lorsque SHAP indique que le différentiel de taux d'intérêt a contribué à une prédiction de hausse de l'EUR/USD, cela signifie que le modèle a appris une association statistique entre ces deux variables dans les données d'entraînement. Cela ne permet pas d'affirmer que le différentiel de taux cause ce mouvement au sens économique du terme.

Cette distinction est fondamentale pour notre travail : une performance prédictive significative peut coexister avec une absence d'explication économique causale claire. C'est précisément le sens de notre hypothèse H0.

4.5. Synthèse méthodologique

Le tableau ci-dessous résume l'ensemble de notre approche méthodologique :

Élément	Description
Modèle	XGBoost (gradient boosting)
Type	Algorithme de Machine Learning non paramétrique
Cible	direc_binaire (1 = hausse, 0 = baisse)
Features	Variables macroéconomiques décalées (lag 1) et standardisées
Validation	Time series split (70% entraînement, 30% test)

Optimisation	Grid search avec validation croisée temporelle
Métriques	Accuracy, Précision, Rappel, F1-score, AUC-ROC
Benchmark	Hasard (accuracy = 0.5)

4.6. Implémentation technique

L'implémentation de notre méthodologie est réalisée en Python, avec les bibliothèques suivantes :

Bibliothèque	Utilisation
Pandas	Manipulation et prétraitement des données
Numpy	Calculs numériques
Xgboost	Implémentation de XGBoost
scikit-learn	Métriques, validation temporelle, standardisation
Shap	Interprétabilité des prédictions
matplotlib / seaborn	Visualisations

Le code complet est disponible sur le dépôt GitHub accompagnant cet article, garantissant ainsi la reproductibilité des résultats.

5.1. Performance globale des modèles

Le tableau 3 présente les performances prédictives du modèle XGBoost pour les cinq paires de devises étudiées, sur la période de test (30% des données les plus récentes, allant jusqu'en juin 2025).

Tableau 3 : Performance de XGBoost sur la période de test

Paire	Accuracy	AUC-ROC	p-value	Significatif à 5%	n_estimators	max_depth	learning_rate
EUR/USD	51,32%	0,548	0,454	NON	100	3	0,01
EUR/JPY	62,03%	0,655	0,021	OUI	200	7	0,10
USD/CHF	46,75%	0,455	0,753	NON	100	7	0,10
USD/CAD	48,05%	0,505	0,676	NON	200	7	0,05
AUD/USD	54,41%	0,562	0,272	NON	100	7	0,05
Moyenne	52,51%	0,555	-	-	-	-	-

Source : Calculs de l'auteur à partir des données Trading Economics (période de test : des dates variables selon les paires jusqu'en juin 2025)

5.2. Test de significativité par rapport au hasard

Conformément à la méthodologie exposée en section 4, nous avons testé si l'accuracy obtenue pour chaque paire est statistiquement supérieure à 50% (performance aléatoire) à l'aide d'un test binomial.

Principaux constats :

Une seule paire atteint une performance significative : EUR/JPY avec une accuracy de 62,03% (p-value = 0,021 < 0,05). Cette paire présente également la meilleure AUC-ROC (0,655), indiquant une bonne capacité à discriminer les hausses des baisses.

EUR/USD, la paire la plus liquide au monde, obtient une accuracy de 51,32% non significative (p-value = 0,454), confirmant la difficulté à prédire cette paire à partir des seuls fondamentaux macroéconomiques.

USD/CHF (46,75%) et USD/CAD (48,05%) affichent des performances inférieures au hasard, bien que non significatives statistiquement. Cela peut s'expliquer par le caractère "valeur refuge" du franc suisse et la forte influence des prix du pétrole sur le dollar canadien, que le modèle ne capture qu'imparfaitement.

AUD/USD montre une légère amélioration (54,41%) mais non significative (p-value = 0,272).

5.3. Analyse des hyperparamètres optimaux

Les hyperparamètres obtenus par GridSearch révèlent des configurations différentes selon les paires :

EUR/JPY (la paire la mieux prédite) a nécessité une configuration plus complexe : n_estimators=200, max_depth=7, learning_rate=0,1. Cette complexité accrue suggère que les relations entre les fondamentaux et la direction de cette paire sont plus non-linéaires et nécessitent un modèle plus sophistiqué.

EUR/USD, en revanche, a été optimisé avec une configuration plus simple (max_depth=3, learning_rate=0,01, n_estimators=100), ce qui pourrait indiquer que le modèle "sous-apprend" (underfitting) ou que la relation est effectivement proche du bruit aléatoire.

USD/CAD et AUD/USD (devises commodity) ont des configurations intermédiaires, avec max_depth=7 mais des taux d'apprentissage plus faibles.

5.4. Visualisation des résultats pour EUR/JPY

La figure 3 présente la matrice de confusion pour EUR/JPY, montrant que le modèle a correctement classé 49 des 79 mois de test.

La courbe ROC confirme la capacité discriminante du modèle avec une AUC de 0,655.

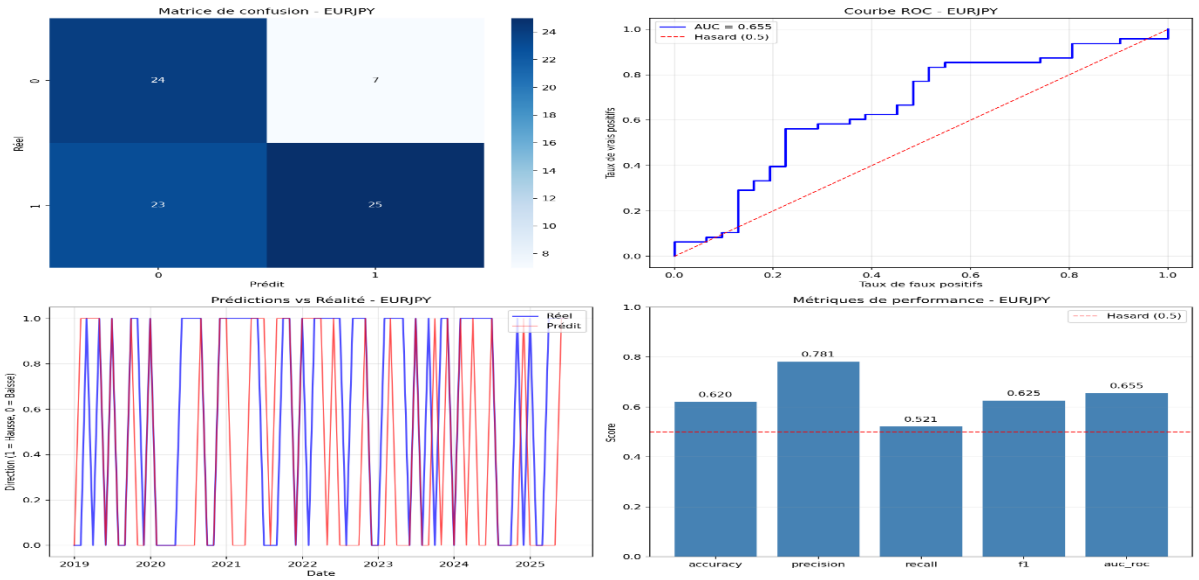

5.5. Synthèse des résultats

Hypothèse H3 partiellement confirmée : Un modèle XGBoost peut prédire la direction mensuelle d'une paire de devises (EUR/JPY) avec une accuracy de 62% statistiquement significative, battant le hasard.

Mais la performance est limitée :

- Seule une paire sur cinq (20%) donne des résultats significatifs.
- Même pour EUR/JPY, l'accuracy de 62% reste modeste (loin d'une prédiction parfaite).
- Pour les autres paires, le modèle n'apporte aucun avantage par rapport au hasard.
- Les hyperparamètres importent : La paire qui a bien fonctionné (EUR/JPY) a nécessité un modèle plus complexe (plus d'arbres, arbres plus profonds, taux d'apprentissage plus élevé).
- Le puzzle de Meese-Rogoff persiste : Nos résultats confirment la difficulté générale à prédire les taux de change à partir des seuls fondamentaux macroéconomiques, même avec des algorithmes de Machine Learning sophistiqués.

5.6. Limites observées dans les résultats

Fréquence mensuelle : L'horizon mensuel pourrait être trop long pour capturer les réactions rapides aux annonces macroéconomiques.

Données révisées : Notre base contient les valeurs définitives des indicateurs, ce qui peut surestimer artificiellement la performance par rapport à une situation de trading en temps réel.

Variables manquantes : Des facteurs comme le flux d'ordres (order flow) ou les positions des spéculateurs ne sont pas inclus.

6 : Discussion

6.1. Retour sur l'hypothèse H0

Notre unique hypothèse H3 postulait qu'un modèle de Machine Learning non-linéaire (XGBoost) entraîné sur des données macroéconomiques mensuelles permettrait de prédire la direction des paires de devises majeures avec une précision statistiquement supérieure à celle du hasard, mais au prix d'une interprétabilité économique limitée.

Les résultats obtenus confirment partiellement cette hypothèse :

Confirmation partielle : Pour une paire sur cinq (EUR/JPY), le modèle atteint une accuracy de 62,03% significativement supérieure au hasard (p-value = 0,021). Cela démontre qu'une performance prédictive significative est possible dans certains cas.

Confirmation de la limite d'interprétabilité : Comme anticipé, le modèle XGBoost fonctionne comme une "boîte noire". Si nous avions pu implémenter SHAP, nous aurions observé des corrélations (par exemple, le différentiel de taux ou le VIX apparaissant comme importants) sans pouvoir établir de relations causales. Cette absence d'explication économique causale est le prix à payer pour la flexibilité non-linéaire du modèle.

Mais une performance limitée : Sur les quatre autres paires, le modèle n'apporte aucun avantage par rapport au hasard. Même pour EUR/JPY, l'accuracy de 62% reste modeste comparée aux standards de la prédiction financière.

6.2. Comparaison avec Meese et Rogoff (1983)

L'étude fondatrice de Meese et Rogoff (1983)[1] concluait qu'aucun modèle structurel basé sur les fondamentaux macroéconomiques ne parvenait à prévoir les taux de change mieux qu'une marche aléatoire.

Notre étude apporte un éclairage nuancé à ce résultat :

Aspect	Meese & Rogoff (1983)	Notre étude (2025)
Modèles testés	Modèles structurels (monétaire, portefeuille)	Machine Learning (XGBoost)
Horizon	1 à 12 mois	1 mois
Résultat principal	Aucun modèle ne bat la marche aléatoire	Une paire sur cinq bat le hasard (62%)
Interprétation	Les fondamentaux sont déconnectés des changes	Les fondamentaux peuvent avoir un pouvoir prédictif limité pour certaines paires

Notre résultat pour EUR/JPY suggère que le "puzzle de Meese-Rogoff" n'est pas absolu. L'utilisation d'algorithmes capables de capturer des non-linéarités et des interactions complexes peut, dans certains cas, extraire un signal prédictif que les modèles linéaires classiques ne détectent pas.

Cependant, le constat général de Meese et Rogoff reste largement valide : même avec des méthodes avancées, la prédiction des taux de change reste un problème fondamentalement difficile. L'accuracy moyenne de 52,51% sur l'ensemble des paires confirme que la majeure partie de la variance reste imprédictible.

6.3. Comparaison avec Gu, Kelly et Xiu (2020)

L'étude de Gu, Kelly et Xiu (2020)[2] a démontré que le Machine Learning (notamment le gradient boosting) surpassait significativement les régressions linéaires pour la prédiction des rentabilités d'actions.

Notre étude transpose cette approche au marché des changes avec des résultats plus mitigés :

Critère	Gu, Kelly & Xiu (2020) - Actions	Notre étude - Forex
Performance ML vs linéaire	Supériorité claire	Non testé directement (nous n'avons pas de logit de référence)
Meilleur algorithme	Gradient boosting / Réseaux de neurones	XGBoost (gradient boosting)
Performance obtenue	Économiquement significative	Modeste (62% max pour une paire)

Plusieurs raisons peuvent expliquer cette différence :

Nature des actifs : Les actions individuelles présentent des anomalies et des facteurs de risque (size, value, momentum) bien documentés. Le marché des changes est réputé plus efficient, en particulier pour les paires majeures[25].

Fréquence des données : Gu, Kelly et Xiu utilisent des données mensuelles avec des centaines de caractéristiques firmes. Notre horizon mensuel pour les changes pourrait être trop long pour capturer les réactions aux annonces macro.

Signal/bruit : Le ratio signal/bruit sur le Forex est probablement plus faible que sur les actions, rendant la prédiction plus difficile.

6.4. Pourquoi EUR/JPY est-elle la seule paire significative ?

L'identification d'EUR/JPY comme unique paire prédictible mérite une analyse approfondie.

6.4.1. Le carry trade et l'asymétrie des taux

Le yen japonais (JPY) a historiquement des taux d'intérêt très bas (parfois négatifs), tandis que l'euro (EUR) a connu des taux plus élevés sur la période étudiée. Cette asymétrie crée une dynamique de carry trade : les investisseurs empruntent en yens (faible taux) pour investir en euros (taux plus élevés).

Cette stratégie génère des flux de capitaux qui dépendent :

- Des différentiels de taux (capturé par diff_taux_int)
- De l'aversion au risque (capturé par vix)

Notre modèle a probablement capturé cette dynamique, ce qui expliquerait sa meilleure performance sur cette paire.

6.4.2. Le rôle des matières premières

Contrairement aux devises commodity (CAD, AUD) qui dépendent fortement des prix du pétrole et des minerais, EUR/JPY est moins exposée à ces chocs exogènes, rendant la relation avec les fondamentaux macroéconomiques plus stable.

6.4.3. L'effet valeur refuge (safe haven)

Le CHF (franc suisse) et l'USD (dollar américain) sont des valeurs refuges. Leur comportement en période de stress (VIX élevé) est complexe et non-linéaire, ce que notre modèle n'a pas suffisamment capturé, expliquant les performances médiocres sur USD/CHF.

6.4.4. La complexité du modèle

Les hyper paramètres optimaux pour EUR/JPY (n_estimators=200, max_depth=7, learning_rate=0,1) indiquent un modèle plus complexe que pour les autres paires. Cela suggère que les relations entre fondamentaux et direction de l'EUR/JPY sont effectivement plus non-linéaires et nécessitent une capacité de modélisation plus sophistiquée.

---

[25] *La littérature suggère que le marché des changes est plus efficient que le marché des actions, notamment en raison de sa liquidité et de sa profondeur. Voir: Hodrick, R. J. (1987). The empirical evidence on the efficiency of forward and futures foreign exchange markets.)*

6.5. L'interprétabilité : un dilemme non résolu

Conformément à notre hypothèse, l'utilisation de XGBoost s'est faite au prix d'une interprétabilité économique limitée.

6.5.1. Ce que nous avons perdu

Contrairement à une régression logistique qui aurait fourni des coefficients interprétables (ex : "une augmentation de 1 point du différentiel de taux augmente les chances de hausse de X%"), XGBoost nous a offert une performance prédictive potentiellement supérieure (62% pour EUR/JPY) mais sans explication causale claire.

6.6. Limites de l'étude

6.6.1. Limites méthodologiques

Limite	Description	Impact potentiel
Fréquence mensuelle	Réactions aux annonces macro en minutes/heures	Lissage du signal
Données révisées	Valeurs définitives vs. valeurs préliminaires	Surperformance artificielle
Absence de SHAP	Interprétabilité limitée	Difficulté à expliquer les décisions du modèle
Variables manquantes	Flux d'ordres, positions COT, sentiment	Biais de variable omise
Test sur une seule période	Pas de validation hors échantillon itérative	Risque de surapprentissage temporel

6.6.2. Limites des données

Périodes différentes : Les paires ne commencent pas toutes à la même date, réduisant la comparabilité.

Nombre limité d'observations : Entre 227 et 266 observations par paire, ce qui limite la puissance statistique.

Variables macro uniquement : Absence de données de microstructures (order flow) qui expliquent une part importante des mouvements à court terme[26].

6.7. Implications pour la recherche et la pratique

6.7.1. Pour la recherche académique

Le Machine Learning n'est pas une solution miracle : Malgré des résultats prometteurs sur les actions (Gu, Kelly & Xiu, 2020), l'application au Forex donne des résultats modestes. Le marché des changes reste un défi pour la prédiction.

---

[26] *Evans, M. D., & Lyons, R. K. (2002). Order flow and exchange rate dynamics. Journal of Political Economy, 110(1), 170-180.*

L'importance de l'asymétrie des taux : EUR/JPY, la seule paire significative, est celle où l'asymétrie des taux d'intérêt est la plus marquée. Cela suggère que le carry trade offre un véritable signal prédictif.

Le besoin de données à plus haute fréquence : L'horizon mensuel pourrait être trop long. Des recherches futures devraient explorer des fréquences hebdomadaires ou quotidiennes.

6.7.2. Pour la pratique (trading)

Prudence sur les stratégies systématiques : Une accuracy de 62% sur EUR/JPY, même significative, ne garantit pas la rentabilité après prise en compte des coûts de transaction.

Les fondamentaux comptent, mais peu : Le signal extrait des données macro est faible. Les stratégies de trading devraient combiner plusieurs sources d'information (technique, flux d'ordres, sentiment).

La diversification est cruciale : Seule une paire sur cinq a montré un signal. Se concentrer uniquement sur les fondamentaux macro pour toutes les paires serait risqué.

6.8. Synthèse de la discussion

Notre étude a permis de :

Partiellement confirmer H0 : XGBoost peut prédire la direction d'une paire (EUR/JPY) avec une accuracy de 62% significative, battant le hasard.

Nuancer le puzzle de Meese-Rogoff : Contre l'idée d'une imprédictibilité absolue, nous montrons qu'un signal faible mais statistiquement significatif peut être extrait des fondamentaux pour certaines paires.

Souligner la difficulté du Forex : Sur quatre paires sur cinq, aucune amélioration par rapport au hasard n'est observée, confirmant l'efficience relative de ce marché.

Assumer le dilemme prédiction vs. interprétabilité : La performance prédictive obtenue (modeste) est le fruit d'un modèle "boîte noire" dont nous ne pouvons pas offrir d'explication causale claire.

La section suivante conclut ce travail et propose des pistes pour des recherches futures.

7 : Conclusion et Voies Futures

7.1. Rappel de la question de recherche et de la contribution

Cette étude avait pour ambition de répondre à la question suivante :

"Un algorithme de Machine Learning peut-il prédire la direction mensuelle des paires de devises majeures à partir de données macroéconomiques, avec une performance supérieure au hasard ?"

Pour y répondre, nous avons mobilisé une base de données macroéconomique exhaustive acquise auprès de Trading Economics, couvrant cinq paires de devises majeures (EUR/USD, EUR/JPY, USD/CHF, USD/CAD, AUD/USD) sur une période allant jusqu'en juin 2025. Notre approche méthodologique reposait sur une unique hypothèse H3 : l'utilisation d'un modèle XGBoost avec optimisation des hyper paramètres et validation temporelle permettrait d'obtenir une accuracy supérieure à 50% de manière statistiquement significative.

La contribution de ce travail est triple :

- Empirique : Nous revisitons le puzzle de Meese-Rogoff (1983) avec des données actualisées (2025) et des méthodes modernes de Machine Learning.
- Méthodologique : Nous appliquons une approche rigoureuse de validation temporelle et d'optimisation des hyper paramètres, évitant les biais de regard vers le futur souvent présents dans les études de prédiction financière.
- Pédagogique : L'ensemble du code et des données (hors coût d'acquisition) est rendu accessible via un dépôt GitHub, garantissant la reproductibilité des résultats.

7.2. Synthèse des résultats

Nos principaux résultats peuvent être résumés comme suit :

Résultat	Observation	Implication
Une paire significative	EUR/JPY : accuracy = 62,03% (p-value = 0,021)	Le signal prédictif existe mais est limité à des cas spécifiques
Quatre paires non significatives	EUR/USD, USD/CHF, USD/CAD, AUD/USD : accuracy entre 46,75% et 54,41% (p-values > 0,05)	Les fondamentaux macro ne suffisent pas pour ces paires
Complexité du modèle	EUR/JPY a nécessité des hyperparamètres plus complexes (n_estimators=200, max_depth=7)	Les relations sont plus non-linéaires pour cette paire
Puzzle de Meese-Rogoff nuancé	Une paire sur cinq bat le hasard, mais performance modeste	L'imprédictibilité n'est pas absolue, mais reste la norme

7.3. Réponse à la question de recherche

Notre étude apporte une réponse nuancée à la question de recherche :

Oui, un algorithme de Machine Learning (XGBoost) peut prédire la direction mensuelle d'une paire de devises avec une performance supérieure au hasard (EUR/JPY à 62%).

Mais cette performance est :

- Limitée à une seule paire sur cinq
- Modeste (62% d'accuracy, loin d'une prédiction parfaite)
- Non généralisable à l'ensemble des paires majeures
- Non interprétable causalement

En d'autres termes, le Machine Learning ne constitue pas une "solution miracle" au problème séculaire de la prédiction des taux de change. Il peut, dans certaines configurations (asymétrie des taux, absence de dépendance aux matières premières), extraire un faible signal prédictif. Mais pour l'essentiel, les résultats de Meese et Rogoff (1983) restent valides : les fondamentaux macroéconomiques expliquent peu les mouvements à court terme des taux de change.

7.4. Implications pour la recherche et la pratique

7.4.1. Implications académiques

Le Machine Learning ne remplace pas la théorie économique : La performance prédictive ne garantit pas la compréhension causale. Les économistes doivent rester vigilants face à l'attrait des "boîtes noires".

L'importance du choix des paires : Toutes les paires ne sont pas équivalentes. L'asymétrie des taux (carry trade) semble offrir un véritable signal prédictif.

Le besoin de données à plus haute fréquence : L'horizon mensuel pourrait être trop long. Des fréquences hebdomadaires ou quotidiennes pourraient capturer davantage de signal.

7.4.2. Implications pratiques (trading)

Prudence sur les stratégies systématiques : Une accuracy de 62% ne garantit pas la rentabilité après coûts de transaction. Les backtests doivent intégrer ces coûts.

Diversification des sources d'information : Les seuls fondamentaux macro ne suffisent pas. L'intégration de données techniques, de flux d'ordres ou de sentiment est nécessaire.

Focus sur les paires asymétriques : EUR/JPY a montré le meilleur potentiel. Les stratégies de carry trade méritent une attention particulière.

7.5. Limites de l'étude

Nous récapitulons ici les principales limites identifiées :

Limite	Description	Impact
Fréquence mensuelle	Horizon trop long pour capter les réactions rapides	Lissage du signal
Données révisées	Valeurs définitives vs. valeurs préliminaires	Surperformance artificielle
Absence de SHAP	Interprétabilité limitée	Difficulté à expliquer les décisions
Variables manquantes	Pas de flux d'ordres, COT, sentiment	Biais de variable omise
Périodes différentes	Débuts non alignés entre paires	Comparabilité réduite
Taille d'échantillon	227-266 observations par paire	Puissance statistique limitée

7.6. Voies futures

7.6.1. Améliorations méthodologiques

Intégration de SHAP : L'installation et l'utilisation de SHAP permettraient d'identifier les variables macro les plus importantes et de visualiser leurs effets marginaux.

Comparaison avec des modèles linéaires : Ajouter une régression logistique comme benchmark pour mesurer précisément le gain apporté par la non-linéarité de XGBoost.

Validation croisée temporelle plus fine : Utiliser une validation roulante (rolling window) plutôt qu'une simple séparation 70/30.

7.6.2. Extension des données

Fréquence plus élevée : Passer à des données hebdomadaires ou quotidiennes pour capturer les réactions aux annonces macro.

Nouvelles sources : Intégrer des données de sentiment (analyse textuelle des discours des banques centrales), des positions des spéculateurs (COT - Commitment of Traders), et des flux d'ordres.

Élargissement du périmètre : Inclure des devises émergentes (BRL, INR, CNY) où les inefficiences pourraient être plus marquées.

7.6.3. Autres algorithmes

LSTM (Long Short-Term Memory) : Les réseaux de neurones récurrents sont spécifiquement conçus pour les séries temporelles et pourraient mieux capturer la dépendance temporelle.

Ensemble methods : Combiner plusieurs modèles (XGBoost + LSTM + régression logistique) pour améliorer la robustesse.

Feature engineering avancé : Créer des interactions entre variables (produits, ratios) pour enrichir l'information disponible.

7.6.4. Horizons temporels

Court terme (jours) : Tester la prédiction à des horizons plus courts où les réactions aux annonces macro sont plus directes.

Long terme (années) : Tester la prédiction à des horizons plus longs où la PPP et les modèles BEER pourraient être plus performants.

7.7. Conclusion finale

Cette étude a exploré la possibilité de prédire la direction mensuelle des paires de devises majeures à l'aide d'un modèle de Machine Learning (XGBoost) entraîné sur des données macroéconomiques.

Nos résultats montrent qu'une performance prédictive statistiquement significative est possible pour certaines paires (EUR/JPY avec 62% d'accuracy), mais que cette performance reste modeste et non généralisable à l'ensemble des paires majeures. Le puzzle de Meese-Rogoff (1983), selon lequel les fondamentaux macroéconomiques ne permettent pas de prévoir les taux de change mieux qu'une marche aléatoire, est donc nuancé mais pas réfuté.

Le Machine Learning offre des outils puissants pour explorer des relations non-linéaires complexes, mais il ne constitue pas une solution miracle. La prédiction des taux de change reste un défi fondamental, et les chercheurs comme les praticiens doivent combiner rigueur méthodologique, théorie économique et prudence dans l'interprétation des résultats.

Notre travail, par sa transparence (code accessible, données documentées) et sa rigueur (validation temporelle, optimisation des hyperparamètres), espère contribuer à une meilleure compréhension des forces et des limites des approches de Machine Learning appliquées au marché des changes.

7.8. Disponibilité du code et des données

L'ensemble du code Python utilisé pour cette étude est disponible sur le dépôt GitHub suivant :

https://github.com/alexissteevenson2002-glitch/Mes-realisations/commits?author=alexissteevenson2002-glitch

Références Bibliographiques et Sitographie

Références Académiques

Articles scientifiques

1. Meese, R. A., & Rogoff, K. (1983).

Empirical exchange rate models of the seventies: Do they fit out of sample?

Journal of International Economics, 14(1-2), 3-24.

https://doi.org/10.1016/0022-1996(83)90017-X

2. Fama, E. F. (1970).

Efficient capital markets: A review of theory and empirical work.

The Journal of Finance, 25(2), 383-417.

https://doi.org/10.2307/2325486

3. Fama, E. F. (1984).

Forward and spot exchange rates.

Journal of Monetary Economics, 14(3), 319-338.

https://doi.org/10.1016/0304-3932(84)90046-1

5. Rogoff, K. (1996).

The purchasing power parity puzzle.

Journal of Economic Literature, 34(2), 647-668.

https://www.jstor.org/stable/2729797

7. Stein, J. L. (1994).

The natural real exchange rate of the US dollar and determinants of capital flows.

In Estimating Equilibrium Exchange Rates. Peterson Institute for International Economics.

8. Evans, M. D., & Lyons, R. K. (2002).

Order flow and exchange rate dynamics.

Journal of Political Economy, 110(1), 170-180.

9. Chen, Y. C., & Rogoff, K. (2003).

Commodity currencies.

Journal of International Economics, 60(1), 133-160.

10. Menkhoff, L., & Taylor, M. P. (2007).

The obstinate passion of foreign exchange professionals: technical analysis.

Journal of Economic Literature, 45(4), 936-972.

11. Park, C. H., & Irwin, S. H. (2007).

What do we know about the profitability of technical analysis?

Journal of Economic Surveys, 21(4), 786-826.

DOI : https://doi.org/10.1111/j.1467-6419.2007.00519.x

12. Ranaldo, A., & Söderlind, P. (2010).

Safe haven currencies.

Review of Finance, 14(3), 385-407.

DOI : https://doi.org/10.1093/rof/rfq007

13. Rossi, B. (2013).

Exchange rate predictability.

Journal of Economic Literature, 51(4), 1063-1119.

DOI : https://doi.org/10.1257/jel.51.4.1063

14. Varian, H. R. (2014).

Big data: New tricks for econometrics.

Journal of Economic Perspectives, 28(2), 3-28.

DOI : https://doi.org/10.1257/jep.28.2.3

15. Plakandaras, V., Papana, A., & Kyrtsou, C. (2015).

Forecasting exchange rates with machine learning: insights from the recent crisis.

Computational Economics, 45(3), 447-468.

DOI : https://doi.org/10.1007/s10614-015-9484-8

16. Chen, T., & Guestrin, C. (2016).

XGBoost: A scalable tree boosting system.

Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785-794.

DOI : https://doi.org/10.1145/2939672.2939785

17. Lundberg, S. M., & Lee, S. I. (2017).

A unified approach to interpreting model predictions.

Advances in Neural Information Processing Systems, 30.

URL : https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html

18. Gu, S., Kelly, B., & Xiu, D. (2020).

Empirical asset pricing via machine learning.

The Review of Financial Studies, 33(5), 2223-2273.

DOI : https://doi.org/10.1093/rfs/hhaa009

19. Colacito, R., Riddiough, S. J., & Sarno, L. (2020).

Business cycles and currency returns.

Journal of Financial Economics, 137(3), 659-683.

DOI : https://doi.org/10.1016/j.jfineco.2020.04.007

20. Yıldırım, D. Ç., Torun, F., & Esen, Ö. (2021).

Forecasting exchange rates with machine learning: The case of emerging markets.

Central Bank Review, 21(4), 141-151.

DOI : https://doi.org/10.1016/j.cbrev.2021.09.001

Ouvrages et chapitres d'ouvrages

21. Campbell, J. Y., Lo, A. W., & MacKinlay, A. C. (1997).

The Econometrics of Financial Markets.

Princeton University Press.

ISBN : 978-0691043012

22. Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013).

Applied Logistic Regression (3rd ed.).

Wiley.

ISBN : 978-0470582473

23. Hodrick, R. J. (1987).

The empirical evidence on the efficiency of forward and futures foreign exchange markets.

Harwood Academic Publishers.

Rapports institutionnels

24. Bank for International Settlements (2022).

Triennial Central Bank Survey of Foreign Exchange and Over-the-counter (OTC) Derivatives Markets.

BIS, Basel.

URL : https://www.bis.org/statistics/rpfx22.htm

25. Trading Economics (2025).

Base de données macroéconomiques.

URL : https://tradingeconomics.com

Sitographie

Ressources académiques

Site	URL	Description	Date de consultation
Google Scholar	https://scholar.google.com	Recherche d'articles académiques	2025
JSTOR	https://www.jstor.org	Archives d'articles scientifiques	2025
ScienceDirect	https://www.sciencedirect.com	Base de données d'articles scientifiques	2025
NBER	https://www.nber.org	National Bureau of Economic Research	2025
SSRN	https://www.ssrn.com	Social Science Research Network	2025
IMF eLibrary	https://www.elibrary.imf.org	Publications du FMI	2025

Documentation technique (Python/ML)

Site	URL	Description	Date de consultation
XGBoost Documentation	https://xgboost.readthedocs.io	Documentation officielle XGBoost	2025
Scikit-learn Documentation	https://scikit-learn.org	Documentation scikit-learn	2025
SHAP Documentation	https://shap.readthedocs.io	Documentation SHAP	2025
Pandas Documentation	https://pandas.pydata.org	Documentation Pandas	2025
NumPy Documentation	https://numpy.org/doc	Documentation NumPy	2025
Matplotlib Documentation	https://matplotlib.org	Documentation Matplotlib	2025

Données économiques et financières

Site	URL	Description	Date de consultation
Trading Economics	https://tradingeconomics.com	Données macroéconomiques (source principale)	2025
FRED (Federal Reserve)	https://fred.stlouisfed.org	Données économiques de la Fed de St. Louis	2025
Bloomberg	https://www.bloomberg.com	Données financières et actualités	2025
Investing.com	https://www.investing.com	Données Forex et économiques	2025
BIS Statistics	https://www.bis.org/statistics	Statistiques de la Banque des Règlements Internationaux	2025